

EduTutor.AI

Technická dokumentácia

Verzia: 1.0

Dátum: Apríl 2026

Projekt: EduTutor.AI

Výstup: Výstup č. 3 — finálna technická dokumentácia

Autor: SORRYWECAN s.r.o.

Grant: 09I05-03-V04-00072



Financované
Európskou úniou
NextGenerationEU

PLÁN [OBNOVY]



ÚRAD VLÁDY
SLOVENSKEJ REPUBLIKY



Obsah

–	Abstrakt	2
§ 1	Prehľad systému a kľúčové metriky	3
§ 2	Architektúra — diagram · repozitár · SSE	6
§ 3	AI služby — LLM · STT · TTS · RAG · DB	10
§ 4	Lipsync systém — vizémy · emócie · validácia	15
§ 5	UE5 — 4 transport adaptery	20
§ 6	Knowledge Base platforma	21
§ 7	Skills · Identita · Cross-session pamäť	22
§ 8	Architektonické rozhodnutia — 6 ADR	24
§ 9	Zátťažové testy a benchmark	25
§ 10	Testovanie a kvalita	27
§ 11	Optimalizované parametre	30
§ 12	Desktop EXE — Electron & NSIS bundling	31
§ 13	Orchestrátor — správa 5-service stacku	33
§ 14	Sprievodca nasadením a odporúčania	35
§ 15	API referencia — ~95 endpointov	37
§ 16	Bezpečnosť · GDPR	39
–	Slovník pojmov	40
–	Známe limitácie systému	42
§ 18	Softvérový produkt — inštalačný balík	43
§ 19	Open-source zverejnenie	45

Abstrakt

EduTutor.AI je hlasovo ovládaná AI tutorská platforma pre slovenský jazyk, vyvinutá ako prototyp novej generácie vzdelávacieho softvéru. Systém kombinuje technológie spracovania reči (STT/TTS), veľké jazykové modely (LLM), retrieval-augmented generation (RAG) a realistickú animáciu 3D MetaHuman avatara s lipsync synchronizáciou do jedného koherentného riešenia — teraz aj ako jedno-klikový Windows .exe inštalátor bez potreby Python, Node, Docker či API kľúčov.

Platforma je modulárna a model-agnostická — každá vrstva (STT, LLM, TTS, RAG) je vymeniteľná za behu bez reštartu. Kľúčovou inováciou je vlastný slovenský **14-viseme lipsync systém**: deterministický grapheme-to-viseme engine optimalizovaný pre slovenské digrafy a palatály (`ch` , `dz` , `dž` , `ť` , `ď` , `ň` , `ř`), nasadený na MetaHuman MHC_Girl avatara v Unreal Engine 5.

Dokument obsahuje kompletnú technickú špecifikáciu všetkých AI služieb, architektonické diagramy, API referencie, výsledky záťažových testov, testovaciu maticu a sprievodcu nasadením. Je primárnym technickým artefaktom pre Výstup č. 3 grantovej zmluvy 09I05-03-V04-00072.

Prehľad systému

1.1 Cieľová skupina a produktové diferenciátory

DIFERENCIÁTOR	DETAIL
3D MetaHuman avatar	Vlastný slovenský 14-viseme lipsync engine, deterministický grapheme-to-viseme pre slovenčinu, MetaHuman MHC_Girl
Jedno-klikový .exe inštalátor	Windows NSIS inštalátor, 5 bundled komponentov, zero-key offline ready (~1.9 GB)
4 UE5 transport adaptery	Web Browser Widget · Pixel Streaming · WS Server · Mock
Asymmetric DI	LLM eager, RAG/TTS lazy → graceful degradation namiesto 500 chýb (ADR-001)
Anonymous-by-default identita	Žiadny signup; X-EduTutor-User-Id header → cookie → UUID (ADR-004, Phase 8a)
Cross-session pamäť	user_profile + episodic_memory + auto-summarizer (Phase 8b)
Zero-key offline režim	Bundled Ollama + faster-whisper + Edge TTS — funguje bez internetu aj API kľúčov
Chamber dizajn	Nový "private mentor chamber" variant — pure-black void + amber accent + audio-reaktívny orb
Hardware Setup modal	Auto-detekcia HW, jednoklikové prepnutie optimálnej STT/LLM/TTS konfigurácie

1.2 Klúčové metriky — aktuálny stav

METRIKA	HODNOTA	DETAIL
Backend API routerov	23	FastAPI Python 3.11+ (<code>tutor-service/app/api/*.py</code> bez <code>__init__.py</code>)
Backend endpointov	~95	≈90 REST + 5 WebSocket (merané <code>grep @router.*</code>)
Backend servisných modulov	30	AI services · Lipsync · KB · Voice Cloning · Cache
Skills (Phase 7)	3	<code>web_search</code> , <code>spaced_repetition</code> , <code>memory</code> —
Learning modes	8	<code>deeptutor · sk · en · learn-en-from-sk · assistant · tutor_practice</code> + <code>_pro</code> variants
LLM providerov	6 + 1	6 natívnych dispatchov (OpenAI · OpenAI-compatible · Anthropic · Ollama · vLLM · local Mistral 7B) + 1 custom-registry slot pre vlastný SK model (napr. Qwen3-14B-sk cez <code>CUSTOM_LLM_QWEN3_URL</code>). Predvolený vLLM model: <code>Qwen/Qwen2.5-32B-Instruct-AWQ</code> (self-hosted RTX 4090). Mistral 7B vo whitelist (<code>mistral:7b</code>) — zero-key default je gemma3:4b.
STT backendov / modelov	5 / 10	<code>mlx-whisper · faster-whisper · Groq · OpenAI · 3× SloPal SK fine-tunes</code> (NaiveNeuron, EMNLP 2025, CC-BY-4.0)
TTS providerov	6	6 v UI dropdown: <code>edge · openai · azure · piper · kokoro · mock</code> . Default = Edge TTS (<code>sk-SK-LukasNeural</code> / Viktória). Piper pre plne offline. (Pozn.: <code>google</code> a <code>omnivoice</code> ostávajú v kóde ako neexponované legacy cesty — v zozname pre Phase 5 cleanup.)
UE5 transport adapterov	4	<code>Web Browser Widget · Pixel Streaming · WS Server · Mock</code>
Slovak visemes	14	<code>sil · aa · ee · ih · oh · uh · cnsnt · ff · th · dd · ss · sh · rr · pp</code>
Emócie (kódové názvy)	9	<code>neutral · celebrating · proud · encouraging_mild · correcting · patient · curious · thinking_deep · surprise</code> (identity passthrough do UE5; <code>chat.py:_UE5_EMOTION_MAP</code> , commit <code>c3c7eeb1</code>)
Frontend stránok	14	<code>App Router · Next.js 15.5 · React 19.2</code>
Desktop .exe verzia	0.7.x	<code>EduTutor-Setup-X.X.X.exe</code> · ~1.9 GB · <code>github.com/sorrywecan/edututor-ai</code>
Bundled komponenty v .exe	5	5 adresárov: backend (CPython 3.11 + FastAPI + faster-whisper + HF cache) · frontend (Next.js standalone) · Ollama · Wilbur · UE5
Zero-key offline	Áno	Ollama LLM (offline) + faster-whisper STT (offline) + Edge TTS (free cloud, no key, vyžaduje internet) + ChromaDB (offline). Pre plne offline TTS: Piper.

METRIKA	HODNOTA	DETAIL
Backend testov	681+	64 test súborov · 0 hard failures · 7 zámerných xfail (merané <code>pytest --collect-only</code> ,)
Frontend testov	1	Vitest · <code>core/src/lib/cleanMarkdown.test.ts</code> v zdrojovom kóde · ostatné UI overené manuálnou QA


1.2 Klúčové metriky — pokračovanie

METRIKA	HODNOTA	DETAIL
K6 záťažových scenárov	6	smoke · rampup · spike · endurance · STT-heavy · school-day (skripty v <code>tests/k6/scenarios/</code> ; výsledky závisia od cieľového HW)
Golden Q&A dataset	354	5 predmetov: OOP (71) · Procedurálne progr. (71) · DSA (71) · IAU (71) · Matematická analýza (70). Plus <code>golden_30.json</code> 30-otázkový subset pre rýchle Hit Rate benchmarky. Súbory: <code>test-files/golden_dataset/{oop,prpr,dsa,iau,ma}.json</code>
E2E latencia chat	3–9 s	Vnímané ~1 s vďaka SSE first-token streaming. Meraná end-to-end od odoslania POST <code>/chat/stream</code> po <code>event: done</code> . Záťažové meranie p95 = 1,69 s (S2 Ramp-up scenár, viď §9) — rozdiel: záťažové scenáre nepoužívajú RAG retrieval ani TTS syntézu (preto kratšia latencia).

Architektúra

Päťvrstvová architektúra: Desktop (Electron .exe) ↔ Frontend (Next 15.5) ↔ Backend (FastAPI ~95 endpointov) ↔ UE5 MetaHuman (4 transport adaptéry) ↔ AI služby (6+1 LLM / 5 STT / 7 reachable TTS providerov).

2.1 Hlavný pipeline



2.2 Repozitár — top-level štruktúra

CESTA	OBSAH
core/	Next.js 15 frontend (App Router, React 19, TypeScript)
tutor-service/	FastAPI backend (Python 3.11+) · ~95 endpointov · 64 testových súborov · 681+ testov
desktop/	Electron desktop launcher + orchestrator + build pipeline—
docs/	Markdown technická dokumentácia, ADRs, load test reporty
tests/	Integration & E2E testy (k6, playwright)
data/	RAG dokumenty + vector DB store (gitignored)
monitoring/	Prometheus + Grafana dashboards
nginx/	Reverse proxy config pre produkčné nasadenie
scripts/	Deploy + utility scripts (<code>deploy_qwen3_vastai.sh</code> , atď.)
start.sh / start.bat	One-command lokálny štart (Mac/Linux / Windows)
docker-compose.yml	Lokálny full-stack vývoj
docker-compose.prod.yml	Voliteľný server-side stack (alternatíva k .exe distribúcii)

SEKCIA 02 (POKRAČ.)

Architektúra — SSE streaming formát

2.3 SSE streaming formát — hlasová konverzácia

Backend streamuje odpoveď cez SSE (Server-Sent Events). Pre každú akumulovanú vetu emituje jeden komplexný event s textom, audiom, emóciou a lipsync dátami naraz:

```
event: context
data: {"type": "context", "chunks": [{"doc": "...", "score": 0.78}]}

event: text
data: {"type": "text", "delta": "Slovensko "}


event: sentence
data: {
  "type": "sentence",
  "text": "Slovensko je krajina v strednej Európe.",
  "audio": "base64(mp3)",
  "emotion": "proud", "intensity": 0.75,
  "viseme_timeline": [{t, viseme, weight}],      ← 14 SK vizémov
  "duration_ms": 2200
}

event: done
data: {"type": "done", "full_text": "..."}

```


§2.3 SSE event timeline — diagram

Sekvenčný diagram k sekci §2.3 SSE streaming formát.



AI služby — optimalizované parametre

3.1 LLM — 6 natívnych dispatchov + 1 custom slot

Runtime-switchable cez `POST /api/v1/llm/switch` (žiadny reštart). Dict-dispatch architektúra — nový provider = ~5 riadkov (ADR-002). **Mistral 7B** je v štartovacom balíku ako lokálny Ollama model (`mistral:7b` vo whitelist `RECOMMENDED_LOCAL`) aj ako natívny `local` provider cez Transformers 4-bit.

PROVIDER	MODEL	BEST FOR	SETUP
OpenAI	<code>gpt-4o-mini</code>	Najlepšia kvalita, fastest cloud	<code>OPENAI_API_KEY</code> —
OpenAI-compatible	OpenRouter / Together / DeepSeek / atď.	Lacné cloud LLMs	<code>OPENAI_BASE_URL</code> + key
Anthropic	<code>claude-haiku-4.5</code>	Vysoká kvalita, lacné	<code>ANTHROPIC_API_KEY</code> —
Ollama	<code>gemma3:4b · qwen2.5:7b · mistral:7b · llama3.2:3b</code>	Plne offline, no API key — bundled v .exe. Whitelist v <code>RECOMMENDED_LOCAL</code> .	<code>ollama serve</code> (auto-detect)
vLLM	<code>Qwen2.5-32B-AWQ</code>	RTX 4090 self-hosted	<code>VLLM_URL</code> —
local (Mistral 7B)	<code>mistralai/Mistral-7B-Instruct-v0.2 · 4-bit Transformers</code>	Offline GPU fallback bez Ollama runtime	<code>USE_LOCAL_LLM=true</code> —
Qwen3-14B-sk (custom slot)	native Slovak	Najlepšia slovenčina (open-source)	<code>CUSTOM_LLM_QWEN3_URL</code> —

PARAMETER	HODNOTA	ZDÔVODNENIE
Temperature	0,6	Tutoring vyžaduje faktickú presnosť — nižšia teplota = menej halucinácií
Top-K / Top-P	40 / 0,9	Nucleus sampling pre plynulosť textu
Max new tokens	1 024	Dostatočné pre tutorský kontext
System prompt (Ollama)	320 tokenov	Znížené z 1 239 → 3,87× redukcia first-token latencie pri <code>provider = 'ollama'</code> . Meranie: tiktoken <code>cl100k_base</code> tokenizer. Implementácia: <code>llm_service.py:682</code> <code>_OLLAMA_SYSTEM_PROMPT</code> . Vid' ADR-006 (nový — predtým neformálne pripísané ADR-002).
Kontextové okno	20 správ / 10-turn rolling	Redis cache, 24h TTL — postačuje pre celú tutorskú reláciu

Si EduTutor, priateľský slovenský vzdelávací asistent. Tykaj študentom.
JAZYK: Vždy odpovedaj po slovensky, správnou gramatikou s diakritikou.
ŠTÝL: Krátko a jasne – max 2-3 vety. Bez markdown, bez emoji, bez odrážok.
ÚLOHA: Pomáhaj so vzdelávacími témami.
PRÍSTUP: Po odpovedi sa opýtaj "Dáva ti to zmysel?" alebo ponúkni ďalší krok.

3.2 STT — 5 backendov, 10 modelov

SloPal SK fine-tunes (NaiveNeuron, EMNLP 2025, CC-BY-4.0) dosahujú 65–70 % redukciu WER oproti base Whisper. Runtime prepínanie: `POST /stt/switch`

BACKEND / MODEL	SK WER	LATENCIA	HW
mlx-whisper-turbo	~32 %	~500 ms	Apple Silicon M1+
faster-whisper-large-v3	~22 %	1.2 s GPU	CUDA / CPU 4 GB+
faster-whisper-sk-small	~25 %	2 s CPU	CPU lightweight
slopal-whisper-large-v3-turbo-sk	~13 %	0.8 s GPU / 3 s CPU	Production SK · bundled v .exe
slopal-whisper-large-v3-sk	~12 %	1.2 s GPU	Max accuracy SK
slopal-whisper-small-sk	~25 %	2 s CPU	Lightweight SK
Groq whisper-large-v3	~22 %	~100 ms	Cloud (free tier)
OpenAI whisper-1	~22 %	~300 ms	Cloud paid
Azure speech-services	~18 %	~200 ms	Cloud paid
mock	—	0 ms	Dev / CI

HISTORICKÝ BASELINE – PÔVODNÉ SK MODEL Y

Pôvodný STT baseline grantového návrhu (PB4) používal `erikbozik/whisper-small-sk` (~58 % WER) a `erikbozik/whisper-large-v3-sk` (~21 % WER). Neskôr ich nahradili SloPal SK fine-tunes — pri rovnakej veľkosti modelu dosahujú ~25 % a ~12 % WER (65–70 % redukcia chyby).

AI služby — TTS providers

3.3 TTS — 6 providerov v UI dropdown

PROVIDER	LATENCIA	SLOVAK	VOICE CLONE	NÁKLADY
Edge TTS (default)	~600 ms	Lukáš, Viktória + EN voices	—	Zadarmo
Piper (lokálne, offline)	~200 ms	sk_SK-lili-medium	—	Zadarmo · offline
Kokoro (lokálne)	~400 ms	čiasťočne	—	Zadarmo
Azure Neural TTS	~250 ms	phoneme timing ±5 ms	—	Platený
OpenAI TTS	~500 ms	čiasťočne	—	Platený
Google Cloud TTS (Chirp3 HD)	~300 ms	Áno	—	Platený
mock	0 ms	—	—	Dev / CI

AZURE TTS – KRITICKÝ DETAIL PRE LIPSYNC PRESNOSŤ ±5 MS

Azure Neural TTS je jediný provider vracajúci phoneme-level timing dáta priamo v API response (±5 ms odchýlka). Edge TTS dodáva word-boundary eventy (±50 ms). Ostatné providery používajú text-estimation slovenský grapheme-to-viseme pipeline (`viseme_timeline.py` , ±25 ms).

3.4 RAG — Retrieval-Augmented Generation

PARAMETER	HODNOTA	ZDÔVODNENIE
Vector DB (default)	ChromaDB (embedded)	Nulová externá závislosť, nasadenie jedným príkazom, ≤10K dokumentov
Vector DB (prod)	Weaviate (Docker)	Škálovateľný backend — <code>VECTOR_DB_BACKEND=weaviate</code> —
Embedding model	paraphrase-multilingual-MiniLM-L12-v2	Natívna podpora slovenčiny, 384-dim vektory
Chunk size	500 tokenov	Optimalizované pre slovenské vzdelávacie texty (80–120 znakov/veta)
Chunk overlap	80 tokenov (16 %)	Zachovanie kontextu na hraniciach chunkov
Top-K (chat RAG)	8	Relevantné bez preplnenia LLM kontextu
Top-K (Ask Mode)	15	Ask Mode vyžaduje širší retrieval pre komplexné otázky
Similarity threshold	0,65 cosine	Default v <code>rag_config.py:59</code> (predtým 0,35). API endpointy hardcodujú odlišne: <code>GET /query</code> = 0,7 a <code>POST /ask</code> = 0,4 — tieto overridey sú v zozname pre Phase 5 cleanup.
Full-Text Search	SQLite FTS5	Doplňkový keyword search, <10 ms
Batch size (embedding)	100	Optimálne pre lokálny hardvér
Latencia retrieval	45 ms avg	ChromaDB embedded, bez sieťového round-tripu
Podporované formáty	PDF · DOCX · XLSX · TXT · MD	Max 50 MB, automaticky chunkované a embedované


3.5 Databáza a cache

KOMPONENT	PARAMETER	HODNOTA
PostgreSQL 15	Prod DB	15-alpine — stabilná LTS, nízka pamäť v Docker
PostgreSQL 15	FTS vyhľadávanie	67 % rýchlejšie (GIN indexy, optimalizácia PB2)
PostgreSQL 15	História konverzácií	45 % rýchlejšie (optimalizácia indexov)
SQLite	Dev default	Zero-config, žiadny Docker pre lokálny vývoj
Redis 7	TTL	24 hodín — automatické čistenie denných relácií
Redis 7	Kontextové okno	20 správ (10-turn rolling v Phase 8b)
Redis 7	Latencia cache	<2 ms (namerané v lokálnom Docker prostredí)

KOMPONENT	PARAMETER	HODNOTA
ChromaDB	Per-user episodic	<code>episodic_<user_id></code> + <code>kb_<name></code> collections
FTS5	Engine	SQLite virtual table — keyword search sidecar, <10 ms

§3.4 RAG pipeline — diagram

Flowchart k sekcii §3.4 RAG — Retrieval-Augmented Generation.



Lipsync systém — integrácia a validácia

4.1 Komparatívna analýza voči grantovým kritériám

TECHNOLÓGIA	SK LIPSYNC	LATENCIA <100 MS	MIT LICENCIA	OFFLINE	METAHUMAN NATÍVNE
Oculus LipSync	EN-only	<50 ms	Meta SDK	Áno	adapter
Convai	čiasťočná	~200 ms	Nie	cloud	plugin
NeuroSync	Nie	~180 ms	Nie	Nie	Áno
AnimaSync WASM	—	130–300 ms	MIT	Áno	—
Vlastný text systém	deterministický	<1 ms	MIT	Áno	native

Zdôvodnenie výberu: EduTutor in-house stack ako jediný spĺňa kombináciu grantových obmedzení (slovenský-first, open-source MIT, offline, no vendor lock-in, MetaHuman native). Convai a NeuroSync sú zrelé komerčné produkty, ale ich SaaS architektúra a komerčná licencia nie sú zlučiteľné s open-source obligáciou Výstupu 3.

4.2 Lipsync produkčná cesta


REŽIM	DÁTA	GPU	PRESNOSŤ	DETEKCIA
Text → Viseme	14 SK viseme labelov + weight + coarticulation array	nie	±25 ms	arkit field chýba

COARTICULATION BLEND

Každý frame v viseme payload-e navyše obsahuje voliteľný visemes sub-array s primary + secondary viseme + weight. Multi-blendshape Blueprinty môžu čítať visemes lista a driviť dve overlapping MetaHuman blendshapes súčasne pre realistickejšiu koartikuláciu. Single-blend Blueprinty čítajú len primary viseme field — backward-compat zachovaná.

§4.2 Lipsync pipeline — diagram

Diagram k sekcii §4.2 (str. 11).



4.3 14 slovenských vizémov

Mapovanie 46 slovenských grafém → 14 viseme tried. Env-tunable durations:

sil ticho / pauza	aa a, á, ä	ee e, é	ih i, í, y, ý
oh o, ó, ô	uh u, ú	cnsnt k, g, h, ch	ff f, v
th t, d	dd ď, ě, n, ň	ss s, z, c	sh š, ž, č, dž
rr r, ř, l, Ľ	pp p, b, m		

PHONEME_DURATION_NORMAL_MS=60

bežná fonéma

PHONEME_DURATION_LONG_VOWEL_MS=100

dlhé samohlásky (á, é, í, ó, ú)

PHONEME_DURATION_FAST_CNSNT_MS=45

rýchle konsonanty

Lipsync systém — 9 emócií

4.4 9 emócií — pedagogicky cielené stavy

#	EMÓCIA	PEDAGOGICKÝ KONTEXT	BLENDSHAPE KANÁLY V PRESETE
1	neutral	Kľudný pozorný baseline	Žiadne (Blueprint auto-blink)
2	celebrating	Žiakov úspech, celebračný úsmev (Duchenne)—	EyeSquintL/R, BrowInnerUp
3	proud	Po zvládnutí konceptu — teplý zatvorený úsmev	EyeSquintL/R, BrowDownL/R
4	encouraging_mild	Jemné pozitívne posilnenie	EyeSquintL/R, BrowInnerUp
5	correcting	Empatická oprava chyby — nie nahnevany—	BrowInnerUp, BrowDownL/R, EyeSquintL/R
6	patient	Opakovaná korekcia — kľudný, nie frustrovaný	BrowInnerUp, EyeSquintL/R
7	curious	Neočakávaná odpoveď — náznak naklonenia hlavy	BrowInnerUp, BrowOuterUpL/R, EyeLookUpL/R, EyeWideL/R
8	thinking_deep	Zložitá otázka — pohľad hore-vľavo, jemné zamračenie	BrowInnerUp, BrowDownL/R, EyeLookUpL/R
9	surprise	Neočakávaná odpoveď — obočia hore, oči široko	BrowOuterUpL/R, EyeWideL/R

4.5 Tri-tier lipsync fallback — presnosť synchronizácie

Systém automaticky volí najkvalitnejší dostupný zdroj časovania. Pri každej TTS syntéze backend detekuje prítomnosť phoneme metadát a zvolí príslušný tier:

TIER	ZDROJ	PRESNOSŤ	PODMIENKA
Tier 1 – Azure phonemes	Azure Neural TTS → phoneme timestamps (100ns jednotky)	±5 ms	Provider = Azure Neural TTS
Tier 2 – Edge WordBoundary	Edge TTS → word-boundary eventy + text anchor	±50 ms	Provider = Edge TTS
Tier 3 – text-only fallback	Slovak grapheme-to-viseme pravidlá (viseme_timeline.py)	±25 ms typ.	Všetky ostatné TTS / offline typ.

4.7 Validačný protokol — code-level dôkazy

TYP VALIDÁCIE	STAV	DETAIL
Deterministické testy	Hotové	165 testov v 6 súboroch (test_lipsync_accuracy.py, test_lipsync_stress.py, test_avatar_simulation.py, test_ws_avatar.py, test_viseme_timeline*.py, test_phonetic_rules.py)
Fonetické pravidlá SK	Hotové	32 testov — devoicing, palatalizácia, diftongizácia, Tier 1 korekcie
WS kontrakt UE5	Hotové	29 testov — ARKit schema, emotion presety, backward-compat
Lipsync codepath audit	Hotový	409 riadkov, 11 súborov, 14 visemes — docs/lipsync_codepath_audit.md

UE5 — 4 transport adaptery

ADAPTER	LATENCIA	SETUP	MULTI-USER	MOBILNÝ	POUŽITIE
Web Browser Widget	~0 ms	EdotutorUE.exe (v bundle)	Nie	Nie	Default — single user, Windows Desktop
Pixel Streaming	~80 ms	WebRTC + Wilbur signalling	Áno	Áno	SaaS, multi-user, cloud GPU
WS Server	~10 ms	UE5 + backend WS	Nie	Nie	Blueprint dev, headless testing
Mock	—	žiadny UE5	Nie	Áno	Frontend dev bez UE5 inštalácie

5.1 UE5 audio streaming — 3 módy (§35)

MÓD	ENV VAR	ČO POSIELA	POUŽITIE
SSE-only (default)	—	Len <code>viseme_timeline</code> . Audio hrá browser.	Štandard — backend riadi animáciu
Stream	<code>EDU_UE5_AUDIO=1</code> —	<code>speech_start</code> + <code>speech_chunk</code> + <code>speech_end</code> —	Real-time audio processing v Blueprint
Full	<code>EDU_UE5_AUDIO_MODE=full</code> —	<code>speech_full</code> (celý MP3 + visemes)	RAI <code>ImportAudioFromBuffer</code> —

5.2 WebSocket handshake a formát

```
// UE5 → Backend: avatar_ready
{ "type": "avatar_ready",
  "capabilities": ["viseme", "emotion", "state"] }

// Backend → UE5: AvatarCommand (každá veta)
{ "type": "viseme",
  "viseme": "aa",          "weight": 0.92,
  "visemes": [{ "viseme": "aa", "weight": 0.92 }, { "viseme": "ee", "weight": 0.4 } ],
  "emotion": "proud",      "intensity": 0.75,
  "isSpeaking": true,      "agentState": "speaking",
  "total_duration_ms": 2200 }
```

UE5 AUDIO STREAMING – BARGE-IN OCHRANA

`POST /api/v1/avatar/stop`: 1. `speech_stop` → UE5 (okamžite stop) · 2. `isSpeaking=false, visemes=[sil]` → zavrieť ústa · 3.

3S MUTE WINDOW

— zabráni in-flight TTS úlohám znovu otvoriť ústa. `EDU_UE5_AUDIO=1` → frontend stíši browser audio (zabráni "double audio").

Knowledge Base platforma

6.1 4 KB režimy

REŽIM	POPIS	PODPORA DOKUMENTOV
Chat Mode	Konverzácia s kontextom z KB (RAG top-k = 8)	PDF · DOCX · XLSX · TXT · MD
Study Mode	AI transformácie: Study Guide, Flashcards, Practice Questions	Per-document transformácie
Voice Mode	Hlasová konverzácia s KB kontextom + avatar	Max 50 MB per dokument
Ask Mode	Cielená Q&A nad jednotlivými dokumentmi (top-k = 15)	Per-document, context_mode toggle

6.2 Databázový model — 9 SQLAlchemy tabuliek

MODEL	TABUĽKA	KLÚČOVÉ STĺPCE
User	users	id (UUID), created_at, last_seen_at
UserProfile (Phase 8b)	user_profiles	user_id (FK), facts (JSON), summary, updated_at
Conversation	conversations	id, user_id, session_name, mode, kb_name, status (ACTIVE/ENDED)
Message	messages	id, conversation_id, role (user/assistant), content, emotion, latency_ms
KnowledgeBase	knowledge_bases	name (PK), description, chunk_count, doc_count
Document	documents	id, kb_name (FK), filename, mime_type, status (PENDING/READY/FAILED), context_mode
Flashcard (Phase 7)	flashcards	id, user_id (FK), question, answer, fsrs_state (JSON), next_review_at
Podcast	podcasts	id, kb_name, title, script (JSON), audio_path, status, duration_ms

Skills Platform · Identita · Cross-session pamäť

7.1 Skills Platform (Phase 7) — 3 Skilly


SKILL	TOOLS	ÚČEL
web_search	search_web, fetch_url	DuckDuckGo HTML search + main-content extraction (trafilatura)
spaced_repetition	add_card, review_card, due_cards	FSRS-style flashcard učenie (SQLite store, FSRS-6 algoritmus)
memory	recall_memory, update_profile	Cross-session user pamäť (Phase 8b, embedding similarity)

7.2 Anonymous-by-default identita (ADR-004) a 3-vrstvová pamäť

VRSTVA	STORAGE	ŽIVOTNOSŤ	ÚČEL
Working memory (L1)	In-memory (per request)	20-turn rolling window	Súčasná konverzácia
Episodic memory (L2)	ChromaDB <code>episodic_<user_id></code> —	Per-session summaries	Predošlé konverzácie (auto-summarizer)
User profile (L3)	SQLite user_profiles	Long-term facts JSON	Meno, záujmy, štýl učenia, ciele

§6.2 Databázový model — ER diagram

Diagram k sekci §6.2 (str. 15).



Architektonické rozhodnutia (ADR)

6 formálnych Architectural Decision Records dokumentuje kľúčové architektonické voľby, ich odôvodnenie a dopad. Plné znenie v [docs/adrs/](#).

001

ACCEPTED

Asymmetric Dependency Injection

LLM eager · RAG/TTS lazy

LLM je *eager-injected* cez `Depends(llm_service_dep)` — pri init failure padne s 500 (nie je použiteľný bez LLM). RAG a TTS sú *lazy* vo vnútri handler-ov — pri failure handler graceful-degraduje (text-only odpoveď). Výsledok: systém nikdy nevráti prázdnu odpoveď, iba degradovanú. Testované v `test_chat_dependency_injection.py` (7 testov).

002

ACCEPTED

Dict-dispatch tables

TTS / STT / LLM / RAG provideri

Provideri pre všetky AI vrstvy sú registrovaní v dict tabuľkách (`_TTS_DISPATCH`, `_STT_DISPATCH`, atď.). Nový provider = ~5 riadkov kódu. Žiadne `if/elif` reťaze, žiadne plugin frameworky. Runtime-switchable cez `POST /api/v1/{llm,tts,stt}/switch` bez reštartu backendu.

003

ACCEPTED

NaiveNeuron attribution

CC-BY-4.0 · SloPal SK fine-tunes

SloPal Whisper fine-tunes (slopal-whisper-large-v3-sk, -turbo-sk, -small-sk) sú CC-BY-4.0 z NaiveNeuron (EMNLP 2025). Attribution je povinný v UI provider selectore a v dokumentácii. Poskytujú 65–70 % redukciiu WER oproti base Whisper pre slovenčinu.

004

ACCEPTED

Anonymous-by-default identita

header → cookie → UUID · žiadny signup

Žiadny signup. Backend extrahuje `user_id` v poradí: `X-EduTutor-User-Id` header → cookie `edututor_user_id` → generate UUID + set cookie. Umožňuje cross-session pamäť a per-user scoping skills bez registrácie. Middleware: `identity.py`.

005

ACCEPTED

UE5 protokol v2.1 — backward-compatible agentState

omit-when-None · byte-identický pre v2 Blueprinty

`agentState` field je úplne vynechaný z payload-u keď `None` — nikdy `null`, nikdy prázdny string. v2 Blueprints vidia byte-identický traffic (žiadna breaking change). Tiež definuje `UE5_BROADCAST_DELAY_MS=180`: browser MediaSource audio buffer štartuje median 180 ms po prvom chunk-u — bez delay avatar otvára ústa pred audio. Pinned testom `test_broadcast_omits_agent_state_when_none`.

006

ACCEPTED

Provider-specific system prompt

Ollama-only krátky prompt · 1 239 → 320 tokenov (3,87×)

Pri `provider = 'ollama'` sa main system prompt nahrádza skráteným `_OLLAMA_SYSTEM_PROMPT` (`llm_service.py:682`) — slovenský konverzačný štýl, krátke vety, žiadny markdown. Meranie tiktoken `cl100k_base` : main prompt = 1 239 tokenov, Ollama prompt = 320 tokenov ($\approx 3,87\times$ redukcia, výrazné zlepšenie first-token latencie pri lokálnom LLM).

Záťažové testy a benchmark

8.1 K6 záťažové scenáre S1–S6 · M2 Pro T0 baseline

Apple M2 Pro 16 GB · LLM: OpenAI gpt-4o-mini (cloud). Systém bol podrobený šiestim scenárom vrátane 8-hodinového komprimovaného school-day simul.

SCENÁR	VU	ITERÁCIE	CHAT P95	5XX	VERDIKT
S1 Smoke	1	54	2.46 s	0 %	PRESLO
S2 Ramp-up	1→100	42 624	1.69 s	0 %	PRESLO
S3 Spike	0→200→0	1 206	22.54 s	0 %	DEGRADED (latencia, nie failures)
S4 Endurance	30	51 984	9.53 s	0 %	Stable, latency drift (cloud LLM tail)
S5 STT-heavy	10	497	10.30 s (STT)	0 %	STT bottleneck (latency-bound, nie failure)
S6 School-day	0→50 sinus	27 503	3.26 s	0 %	PRESLO — k6 exit 0

118 234 HTTP REQUESTOV Naprieč S1–S6	0× 5XX CHÝB 100 % HTTP success
100 % K6 CHECKOV PASSED 190 531 checksov	

Zátazové testy — Cross-GPU benchmark

8.2 Cross-GPU benchmark — LLM inferencia (Ollama)

TIER	HARDWARE	QWEN2.5:7B	QWEN2.5:14B	ZRÝCHLENIE
T0 – baseline	MacBook Pro M2 Pro (MPS)	32.6 t/s	14.8 t/s	1.0× (baseline)
T2 – measured	NVIDIA RTX 4090 24 GB	168.9 t/s	91.5 t/s	5.2× / 6.2×

8.3 GPU Decision Matrix — produkčné nasadenie pre školy

USE CASE	GPU	MODEL	ODPOVEĎ (200 TOK)	SÚBEŽNÍ ŠTUDENTI
Učiteľský laptop / demo	Apple M2 Pro 16 GB	qwen2.5:7b	6.1 s	1–2
Malá trieda (≤15)	RTX 4060 Ti 16 GB ¹	qwen2.5:7b	~2.0 s	8–10
Trieda (≤30)–	RTX 4090 24 GB	qwen2.5:14b	2.2 s	14–25
Školský lab (≤100)	2× RTX 4090	qwen2.5:32b ²	~3.0 s	50–70
Krajský (≤500)	A100 40 GB	qwen2.5:32b	~1.5 s	200–300
Národné (≤2 000)	A100 80 GB / H100	qwen2.5:32b FP16	~1.0 s	500–1 000

¹ Extrapolované z RTX 4090 dát (4060 Ti ~60 % výkonu). · ² qwen2.5:32b (~20 GB quantized) — vyžaduje 2× GPU alebo A100 40 GB.

Testovanie a kvalita

9.1 Test corpus — autoritatívny stav

681+ BACKEND TESTOV 64 test súborov	1 FRONTEND TEST SÚBOR Vitest · cleanMarkdown
354 GOLDEN Q&A OTÁZOK 5 predmetov · OOP/PRPR/DSA/IAU/MA	

9.2 Top 25 testových súborov (výber)

TEST SÚBOR	POČET	OBLASŤ
test_phonetic_rules.py	32	Slovak fonetické pravidlá (devoicing, palatalization, diphthongs)
test_viseme_timeline_deep.py	31	Hĺbkové vizém testy (~39 s parametrize)
test_ws_avatar.py	29	UE5 broadcaster + WS contract + ARKit schema
test_viseme_timeline.py	23	Vizém generovanie pipeline
test_emotion_detector_deep.py	23	9 emócií klasifikácia (regex SK + BERT)
test_knowledge_base_api.py	22	KB CRUD + search + per-document context mode
test_memory_service.py	21	Rolling 20-turn pamäť + JSON persistencia
test_avatar_simulation.py	20	E2E avatar pipeline bez UE5
test_chat_deep.py	18	Chat endpoint coverage (SSE, errors, modes)
test_rag_edge_cases.py	18	RAG edge cases (empty KB, special chars, very long docs)
test_lipsync_accuracy.py	17	Viseme accuracy contract (49/50 pass, 1 intentional digraph skip)
test_tts_voice_routing.py	16	TTS provider routing + voice picker

SEKCIA 10 (POKRAČ.)

Testovanie — Top testové súbory (pokrač.)

9.2 Top testové súbory — pokračovanie

TEST SÚBOR	POČET	OBLASŤ
test_web_search_skill.py	12	Phase 7 WebSearchSkill
test_learning_modes.py	11	8 LearningModes
+ ~48 ďalších súborov	~291	Auth, profile, podcast, avatar audio streaming, Chamber, ...

Testovanie a kvalita

9.3 Zámerné xfail testy — 7 dokumentovaných (audit docs/audits/2026-05-17/)

TEST	TYP	DÔVOD
test_t_before_e/i/i_produces_TH_viseme (×3)	strict=True	Tier 1 SK korekcia: palatalizované t→DD, nie TH
test_t_palatalization_in_word_context	strict=True	'ste' produkuje SS-DD-E nie SS-TH-E
test_slovak_special_chars['t'-TH]	strict=True	t→DD per Tier 1
test_from_azure_phonemes	strict=False	Azure L fonéma (60 ms) kratšia ako 80 ms grid
test_azure_100ns_to_ms_conversion	strict=False	AA fonéma (50 ms) padá medzi grid pointy — čaká grid tuning

GOLDEN DATASET – 354 OTÁZOK Z 5 PREDMETOV

OOP (71) · Procedurálne programovanie (71) · DSA (71) · Inteligentná analýza dát (71) · Matematická analýza (70). Plus golden_30.json 30-otázkový subset pre rýchle Hit Rate benchmarky. Súbory: test-files/golden_dataset/{oop,prpr,dsa,iau,ma}.json . Generátor: scripts/generate_golden_dataset.py , validátor: scripts/validate_golden_dataset.py . Spustenie: python tests/benchmark_rag.py

Optimalizované parametre

Kompletný katalóg 250+ konfiguračných parametrov so zdôvodnením je v `docs/PARAMETERS_REFERENCE.md` (2 503 riadkov, 14 sekcií). Nižšie sú kľúčové optimalizované hodnoty a tri HW profily.

10.1 Tri HW profily

PROFIL	CIEĽOVÝ HW	LLM	STT	TTS	RAG
Zero-key–	8 GB RAM, Windows	Ollama gemma3:4b	faster-whisper bundled	Edge TTS	ChromaDB
MacBook–	Apple M2/M3, 16 GB	Ollama qwen2.5:7b	mlx-whisper-turbo	Piper SK / Edge TTS	ChromaDB
Server–	RTX 4090+, 32 GB	vLLM / Qwen3-14B-sk	slopal-whisper-large-v3-sk	Azure Neural TTS	Weaviate

10.2 Kľúčové optimalizované hodnoty

PARAMETER	HODNOTA	ZDÔVODNENIE
UE5_BROADCAST_DELAY_MS	180 ms	Synchronizácia avatar-ústa s browser audio buffer (medián 180 ms, ADR-005)
PHONEME_DURATION_NORMAL_MS	60 ms	Konverzačné tempo slovenčiny — ladené pre prirodzenú artikuláciu
PHONEME_DURATION_LONG_VOWEL_MS	100 ms	Dlhé samohlásky (á, é, í, ó, ú) vyžadujú dlhšiu perzistenciu vizémy
PHONEME_DURATION_FAST_CNSNT_MS	45 ms	Rýchle konsonanty absorbované do coarticulation blend
LLM_TEMPERATURE	0.6	Faktická presnosť pre tutoring — nižšia = menej halucinácií
RAG_CHUNK_SIZE	500	Optimalizované pre slovenské texty (priemerná dĺžka vety 80–120 znakov)
RAG_TOP_K	8 / 15	Chat = 8 (relevantné bez preplnenia LLM); Ask Mode = 15 (širší retrieval)
RAG_SIMILARITY_THRESHOLD	0.65	Minimálna cosine similarity; opravené v aktuálnej verzii (predtým 0.35)
RAG_CHUNK_OVERLAP	80 tokenov	Zachovanie sentence boundary kontextu na hraniciach chunkov
VECTOR_DB_BACKEND	chroma / weaviate	ChromaDB pre ≤10K dokumentov; Weaviate pre produkčné multi-tenant
Redis TTL	24 h	Automatické čistenie denných relácií
System prompt (Ollama)	320 tokenov	Znížené z 1 239 → 3,87× first-token latencia pri <code>provider='ollama'</code> . Viď ADR-006.

KONZISTENCIA PARAMETROV – OVERENÉ

`.env.example` a kódové `rag_config.py` defaults sú synchronizované (predtým existovala nezhoda 120 vs 80 + 0.35 vs 0.65). Validácia cez Pydantic `Field(ge=..., le=...)` constraints. Pre každý profil existuje `deploy/profiles/{zero-key,light,macbook,power,server}.env`.

Desktop EXE — Electron & NSIS bundling

Jedno-klikový Windows .exe inštalátor s celým stackom — žiadny Python, Node.js, Docker ani API kľúče potrebné. Artifact: `EduTutor-Setup-X.X.X.exe` , ~1.9 GB, 5 release-ov.

11.1 Bundled komponenty

KOMPONENT	VEĽKOSŤ (≈)	ČO ROBÍ
CPython 3.11 (embedded)	~80 MB	Self-contained Python runtime, izolovaný cez <code>python311._pth</code> —
FastAPI backend	~100 MB	AI tutor service + ~95 endpointov
Next.js frontend (standalone)	~200 MB	Webové rozhranie, standalone mód (<code>server.js</code>)
Ollama (CPU-only)	~122 MB	Lokálny LLM runtime — modely sa sťahujú pri prvom spustení
faster-whisper STT	~131 MB	Lokálny STT engine, whisper-base model auto-download
Wilbur (Pixel Streaming)	~10 MB	Pixel Streaming signalling server
UE5 avatar (SlovakEdu.exe)	~2.3 GB	Cooked MetaHuman build (Pak files)

Desktop EXE — Build pipeline · kľúčové súbory

11.2 Build pipeline — stage-resources.mjs (5 stages)

01	Frontend pnpm build s NEXT_PUBLIC_SKIP_AUTH=true + kopírovanie standalone + .next/static + patch pnpm siblings + vytvorenie frontend.tgz
02	Backend + Smoke test Kopírovanie tutor-service/app/ , pruning __pycache__ , bundlovanie msvcp140.dll , python311._pth . Hard CI gate: python.exe -c "import app.main"
03	Wilbur Kopírovanie vendored wilbur.bundle.cjs + www/ (Pixel Streaming signalling)
04	Ollama Kopírovanie Ollama, stripping GPU runtimeov (CUDA ~3 GB, ROCm ~2 GB), uninstaller, updater
05	UE5 (--heavy) Kopírovanie cooked buildu (~2.3 GB) · trigger: node stage-resources.mjs --heavy

11.3 Kľúčové súbory

SÚBOR	RIADKOV	ÚČEL
desktop/main.mjs	163	Electron main process · splash · window · error dialog
desktop/orchestrator.mjs	412	Stack lifecycle manager (5 procesov)
desktop/stage-resources.mjs	247	Build pipeline — 5 stages
desktop/preload.cjs	9	Context bridge (window.eduLauncher)
desktop/splash.html	166	Cinematic splash screen — amber orb + rotujúce slová

Orchestrátor — správa 5-service stacku

`desktop/orchestrator.mjs` (412 riadkov) — shell-agnostický Node.js modul riadiaci životný cyklus všetkých 5 servisov. Importovaný z Electron `main.mjs`, funguje aj standalone (`node orchestrator.mjs`).

12.1 5 servisov — špecifikácia

#	SERVIS	PORT	CRITICAL	REŠTART	TIMEOUT
1	Ollama	11434	Nie	Áno (5× cap)	30s · ak beží systémový, preskočí sa
2	Backend	8000	Áno	Áno (5× cap)	90s · HTTP health check <code>/api/v1/health</code> · 5× crash → fatal dialog
3	Frontend	3000	Áno	Áno (5× cap)	90s · <code>standalone</code> <code>server.js</code> alebo <code>pnpm dev</code> —
4	Wilbur	80+8888	Áno	Áno (5× cap)	45s · port 80 player, 8888 streamer
5	UE5	—	Nie	Nie—	3s sleep · <code>noRestart=true</code> · root stub + game = 2 procesy

12.2 Auto-reštart s exponential backoff

Crash #1 → 1s · #2 → 2s · #3 → 4s · #4 → 8s · #5 → 15s
Crash #6 (v 60s okne) → GIVE UP → `emit('service-failed')` → fatal dialog

60s sliding window: ak od prvého crashu uplynulo >60s, počítaadlo sa resetuje.
Dependent reštart: ak backend reštartuje, UE5 sa bounce (nemá auto-reconnect).

12.3 Dual-stack health probe (Windows IPv6 fix)

```
function portListening(port) {
  const probe = (host) => new Promise((r) => {
    const s = createConnection({ port, host });
    s.once('connect', () => { s.destroy(); r(true); });
    s.once('error', () => r(false));
    s.setTimeout(700, () => { s.destroy(); r(false); });
  });
  // uvicorn host="::" viaže IPv6-only → probe oba stacky
  return Promise.all([probe('127.0.0.1'), probe('::1')]).then(([v4,v6]) => v4||v6);
}
```

12.4 Graceful shutdown

1. Označí všetky procesy ako `intentional` (zabráni reštartom) · 2. `taskkill /PID <pid> /T /F` pre každý proces · 3. Safety sweep UE5 + `CrashReportClient` · 4. `SIGINT/SIGTERM` → automaticky `shutdownAll()` + `process.exit(0)`

§12.1 Orchestrator — state diagram

Diagram k sekcii §12.1 (str. 21).

SEKCIA 14

Sprievodca nasadením — odporúčania

13.1 Windows .exe inštalátor (odporúčaná cesta pre koncových používateľov)

Stiahni `EduTutor-Setup-X.X.X.exe` z GitHub Releases, spusti inštalátor, otvor EduTutor.AI. **Žiadny Python, Node, Docker ani API kľúče nie sú potrebné.**

Prvé spustenie: 1. Splash screen s dýchajúcim amber orb-om · 2. FirstRunSetup: detekuje Ollama → ponúkne stiahnutie modelu alebo cloud API kľúč · 3. Skip → zero-key offline režim. Inštalácia: NSIS per-user, writable dáta do `%APPDATA%/EduTutor/`, VC++ Runtime DLLs pribalené.

13.2 Lokálne (bez Docker, pre vývojárov)

```
git clone https://github.com/sorrywecan/edututor-ai.git
cd edututor-ai
./start.sh      # Mac / Linux
# start.bat     # Windows

# Demo login:
Email:    demo@edututor.sk
Password: edututor2026
```

13.3 Docker Compose (voliteľný server-side stack)

V repozitári sú dodávané 3 docker-compose súbory (`docker-compose.yml` , `docker-compose.prod.yml` , `docker-compose.release.yml`) ako alternatíva k .exe distribúcii pre inštitucionálne serverové nasadenie. Primárny deliverable je Windows .exe inštalátor — Docker je dodatočná možnosť.

```
docker compose -f docker-compose.prod.yml up -d
# Stack: Next.js 15 · FastAPI · Nginx · PostgreSQL 15 · Redis 7 · Prometheus · Grafana
```


Sprievodca nasadením — 5 tierov a zero-key stack

13.4 5 nasadzovacích tierov — odporúčania

TIER	POUŽITIE	POTREBNÉ KLÚČE	HW	.ENV PROFIL
Zero-key	Single user, doma / škola	Žiadne	8 GB RAM, Windows	zero-key.env
Light	Single user, cloud LLM	OpenAI alebo Anthropic	4 GB RAM	light.env
MacBook	Single user, lokálny LLM	Žiadne	Apple M1+, 16 GB	macbook.env
Power	1 trieda (~30 žiakov)	OpenAI alebo VLLM_URL	RTX 4090, 64 GB	power.env
Server	Inštitucionálne nasadenie	OpenAI + Azure alebo VLLM_URL	A100 / RTX 4090, 32+ GB	server.env

13.5 Zero-key offline stack — čo funguje bez internetu a API kľúčov

VRSTVA	ZERO-KEY PROVIDER	KVALITA	LIMITÁCIA
LLM	Ollama bundled (gemma3:4b)	Dobrá	Menšie modely = menej presné
STT	faster-whisper bundled (whisper-base)	Dobrá	~145 MB model, auto-download
TTS (online)	Edge TTS (free, no key)	Výborná	Vyžaduje internet
TTS (offline)	Piper sk_SK-lili-medium	Dobrá	~50 MB ONNX model, prepni v Settings
RAG	ChromaDB embedded + ONNX	Dobrá	Limit ~10K dokumentov

SEKCIA 15

API referencia — ~95 endpointov

Swagger UI: `http://localhost:8000/docs` · ~90 REST + 5 WebSocket (merané grep `@router.{get,post,put,delete,patch,websocket}` v `tutor-service/app/api/`)

METÓDA	ENDPOINT	POPIS
GET	<code>/health</code> · <code>/health/ready</code>	<i>Liveness + readiness probe</i>
POST	<code>/chat/stream</code>	<i>Hlavný chat hot path — SSE streaming (text + audio + emotion + visemes)</i>
POST	<code>/chat/stop</code>	<i>Barge-in stop + 3s mute window</i>
GET	<code>/conversations</code>	<i>Zoznam konverzácií pre používateľa</i>
GET	<code>/conversations/{id}</code>	<i>Detail konverzácie vrátane správ</i>
DEL	<code>/conversations/{id}</code>	<i>Zmazanie konverzácie</i>
POST	<code>/knowledge-bases</code>	<i>Vytvorenie novej Knowledge Base</i>
GET	<code>/knowledge-bases</code>	<i>Zoznam KB pre používateľa</i>
POST	<code>/knowledge-bases/{name}/upload</code>	<i>Upload dokumentu (PDF/DOCX/XLSX/MD) — max 50 MB</i>
POST	<code>/knowledge-bases/{name}/search</code>	<i>Vector + FTS5 hybrid search v KB</i>
POST	<code>/knowledge-bases/{name}/ask</code>	<i>Ask Mode — cieľená Q&A (top-k = 15)</i>
POST	<code>/transformations</code>	<i>Study Guide, Flashcards, Practice Questions z dokumentu</i>

SEKCIA 15 (POKRAČ.)

API referencia — ~95 endpointov

POST	/podcasts/generate	Async podcast generácia z KB (multi-speaker, FFmpeg concat)
GET	/podcasts/{id}/status	Stav generovania podcastu
POST	/stt/transcribe	Speech-to-text — audio blob → text (5 backendov)
POST	/stt/switch	Runtime prepínanie STT backendu (žiadny reštart)
POST	/tts/synthesize	Text-to-speech — 6 reachable providerov (Edge default)
POST	/tts/switch	Runtime prepínanie TTS providera
POST	/llm/switch	Runtime prepínanie LLM providera (6 native + 1 custom slot)
POST	/avatar/stop	Okamžité zastavenie avatara (barge-in)
GET	/avatar/status	Status WebSocket a počet pripojených UE5 klientov
POST	/system/config	Validácia + uloženie API kľúčov do %APPDATA%\env
GET	/modes	Zoznam 8 learning modes + ich konfigurácia
WS	/ws/avatar	WebSocket bridge pre UE5 — emócie, 14 vizémov, viseme_timeline

Bezpečnosť

VRSTVA	OPATRENIE	DETAIL
Autentifikácia	NextAuth.js	Credentials / OAuth — session-based auth · anonymous-by-default identita (ADR-004)
API kľúče	Server-side only	<code>.env</code> (gitignored), nikdy v client bundli; desktop: <code>%APPDATA%/EduTutor/.env</code> —
CORS	Whitelist origins	Konfigurovateľné cez env var
Upload limit	50 MB	Ochrana pred DoS útokmi cez file upload
Rate limiting	Per-IP	Nginx + aplikačná vrstva (FastAPI middleware)
SQL Injection	SQLAlchemy ORM	Parameterized queries, žiadny raw SQL
XSS	React auto-escaping	+ Content Security Policy headers (Nginx)
Secrets	<code>.env</code> (gitignored)	Credentials nikdy v repozitári · <code>python311._pth</code> izolácia v <code>.exe</code>
Docker	Non-root user	Minimálne oprávnenia v kontajneri
TypeScript strict	Žiadny <code>as any</code> / <code>@ts-ignore</code>	Hard block — <code>clean npm tsc --noEmit</code> pred každým buildom

16.2 GDPR a ochrana osobných údajov

OBLASŤ	STAV	DETAIL
Identita	Anonymous-by-default (ADR-004)	Žiadny signup; <code>user_id</code> = UUID generované v cookie. Žiadne email/meno povinné.
Lokálne dáta	Plne lokálne	Konverzácie + KB + flashcards v <code>%APPDATA%/edututor-desktop/data/</code> . Žiadny cloud upload bez explicitného API key nastavenia.
Cloud providery	Voliteľné, opt-in	OpenAI / Anthropic / Edge TTS sa použijú IBA ak používateľ zadá API key. Inak plne offline cesta (Ollama + faster-whisper + Piper + ChromaDB).
Logging	Lokálne súbory	<code>%APPDATA%/edututor-desktop/logs/</code> (launcher / backend / UE5 / wilbur). Žiadny telemetry uplink.
Právo na vymazanie	User-controlled	Vymazanie <code>data/</code> adresára → kompletné vymazanie konverzácií, KB, profilu.
Data Processing Agreement	Per cloud provider	OpenAI / Anthropic / Azure majú vlastné DPA. Edge TTS používa anonymné requesty bez user-ID.

SLOVNÍK

Slovník technických pojmů

Definice klíčových technických pojmů použitých v tomto dokumente, pro čitatele bez specializovaného AI/SWE background-u.

POJEM	DEFINÍCIA
LLM (Large Language Model)	Veľký jazykový model tréňovaný na rozsiahlych textových dátach (napr. GPT-4o, Claude, Mistral 7B). Generuje text na základe vstupného promptu.
STT (Speech-to-Text)	Prepis hovoreného slova na text. V EduTutor cez Whisper (SloPal SK fine-tunes pre slovenčinu).
TTS (Text-to-Speech)	Syntéza textu na hovorenú reč. V EduTutor cez Edge TTS (default, sk-SK-LukasNeural / Viktória).
RAG (Retrieval-Augmented Generation)	Architektonický pattern: pred LLM dotazom sa z vektorovej DB vyhľadajú relevantné dokumenty (retrieval) a vložia sa do LLM kontextu (augmented generation). Eliminuje halucinácie a umožní LLM odpovedať na otázky z dokumentov ktoré nikdy nevidel pri tréningu.
Embedding	Číselná reprezentácia textu (vektor v 384-rozmernom priestore pre MiniLM-L12-v2). Semanticky podobné texty majú podobné vektory — to umožní vyhľadávanie podľa významu, nie len kľúčových slov.
Cosine similarity	Miera podobnosti dvoch vektorov (0–1). 0 = ortogonálne (žiadny vzťah), 1 = identické. EduTutor používa threshold 0,65 pre RAG retrieval.
Chunking	Rozdelenie dlhého dokumentu na menšie kúsky (chunky) — typicky 500 tokenov s 80-token overlapom. Každý chunk sa embedne separátne pre granulárnejšie vyhľadávanie.
Top-K	Pri RAG retrieval: počet najlepších výsledkov ktoré sa vrátia. Top-K = 5 znamená 5 najpodobnejších chunkov.
Vektorová DB	Databáza optimalizovaná na vyhľadávanie podľa cosine similarity vo vysokorozmerných vektorových priestoroch. ChromaDB (default, embedded) alebo Weaviate (produkčný server).
Viseme	Vizuálna jednotka reči — tvar úst zodpovedajúci fonéme. Anglické „PP“ pre p/b/m, „aa“ pre a, atď. EduTutor má 14 vizémov pre slovenčinu.
Grapheme	Najmenšia jednotka písaného textu (písmeno alebo digraf). Slovenčina má 46 grafém (vrátane <code>ch</code> , <code>dz</code> , <code>dž</code>) ktoré mapujú na 14 vizémov.
Coarticulation	Lingvistický jav: tvar úst pri jednej fonéme je ovplyvnený susednými fonémami. EduTutor coarticulation array v JSON payload-e dovoľuje 2 blendshapes naraz pre realistickejší pohyb úst.
Phoneme	Najmenšia jednotka hovorenej reči (zvuk). Slovenčina má cca 46 foném.
Blendshape	3D animačná technika: morfovanie medzi rôznymi tvarmi tváre (ústa otvorené, úsmev, atď.). MetaHuman používa ARKit blendshape set.
MetaHuman	Realistický 3D human-character framework v Unreal Engine 5 od Epic Games. EduTutor používa MHC_Girl avatar.
SSE (Server-Sent Events)	HTTP technika pre server-to-client streaming. Server posiela <code>event: name / data: { ... }</code> sekvenčne ako prichádzajú. EduTutor používa SSE pre streamovanie LLM odpovedí token-po-tokene.

POJEM	DEFINÍCIA
WebSocket (WS)	Plne duplexný TCP-based protokol pre real-time komunikáciu. EduTutor používa WS pre <code>/ws/avatar</code> bridge medzi backend-om a UE5.

Slovník technických pojmov — pokračovanie

POJEM	DEFINÍCIA
Pixel Streaming	Unreal Engine technika: UE5 renderuje 3D scénu, výsledné pixely streamuje cez WebRTC do prehliadača. Avatar sa renderuje na server, klient vidí video.
Phoneme timing	Časové značky pre každú fonému vo vygenerovanom audio. Azure Neural TTS ich poskytuje s presnosťou ±5 ms, Edge TTS cez word-boundary ±50 ms.
WER (Word Error Rate)	Štandardná metrika kvality STT: percentuálny počet nesprávne prepísaných slov. SloPal SK má WER ~13 % pre slovenčinu (base Whisper ~30–40 %).
VU (Virtual User)	K6 záťažový test: simulovaný používateľ ktorý opakovane volá API. „10 VU“ znamená 10 paralelných simulovaných používateľov.
p95 / p99 latency	Percentily latencie: p95 = 95 % requestov bolo rýchlejších; p99 = 99 % rýchlejších. Lepšia metrika ako priemer (priemer skrýva tail latency).
NSIS (Nullsoft Scriptable Install System)	Open-source inštalátor pre Windows. EduTutor používa NSIS via electron-builder pre <code>EduTutor-Setup-X.X.X.exe</code> (per-user install bez admin).
Electron	Framework pre desktop aplikácie cez Chromium + Node.js. EduTutor wraps backend + frontend + AI services do jediného .exe.
FastAPI	Moderný Python web framework s automatickým OpenAPI/Swagger documentation generation. EduTutor backend, port 8000.
SQLAlchemy	Python ORM (Object-Relational Mapper) pre prácu s databázami. EduTutor používa pre 9 tabuliek (User, Conversation, Message, KB, atď.).
Next.js	React framework s App Router architektúrou. EduTutor frontend, port 3000.
Ollama	Open-source nástroj na lokálne spustenie LLM (gemma3:4b, qwen2.5:7b, mistral:7b, llama3.2:3b). Bundled v EduTutor .exe pre zero-key offline mód.
vLLM	Open-source serving framework pre LLM optimalizovaný na GPU. Pre RTX 4090 self-hosted Qwen2.5-32B-AWQ.
ADR (Architectural Decision Record)	Krátky dokument popisujúci jedno architektonické rozhodnutie + dôvod + alternatívy. EduTutor má 6 ADR v <code>docs/adrs/</code> .
Zero-key offline	Mód EduTutor-u kde funguje bez akéhokoľvek API kľúča: Ollama LLM + faster-whisper STT + Edge TTS (free, no key) + ChromaDB. Vyžaduje internet pre Edge TTS.
HF (Hugging Face)	Platforma pre hosting ML modelov a datasetov. EduTutor sťahuje MiniLM-L12-v2 (RAG embedding) a faster-whisper modely odtiaľ.
FSRS (Free Spaced Repetition Scheduler)	Algoritmus pre spaced repetition learning (Anki-style flashcards). EduTutor Phase 7 spaced_repetition skill používa FSRS-6.

ZNÁME LIMITÁCIE

Známe limitácie systému

Limitácie aktuálnej dodávky (v0.7.x). Žiadna z týchto limitácií neblokuje funkčnosť pre cieľovú skupinu — vzdelávacie nasadenie pre 1–30 študentov.

OBLASŤ	LIMITÁCIA	WORKAROUND
STT na CPU	Pre 60 s audio je latencia ~10 s na CPU bez GPU	Použiť Groq cloud STT (~100 ms) alebo lokálnu GPU (faster-whisper CUDA ~1,2 s)
Lokálny LLM (Ollama gemma3:4b)	>10 súbežných users → p95 >10 s	Cloud LLM (OpenAI/Anthropic) alebo RTX 4090 self-hosted vLLM
ChromaDB	>10 000 dokumentov v jednej KB degraduje retrieval	<code>VECTOR_DB_BACKEND=weaviate</code> pre väčšie korpusy
Edge TTS	Vyžaduje internet (free cloud, no API key, ale online)	Piper SK lokálne (<code>USE_EDGE_TTS=false</code>) pre plne offline
Text-only viseme path	±25 ms presnosť sync (oproti ±5 ms s Azure phonemes)	Azure TTS pre demo (vyžaduje paid Azure subscription)
UE5 PixelStreaming	Vyžaduje GPU server pre multi-user; single-user na laptop OK	Web Browser Widget (default) pre single-user; PS pre cloud multi-user
Voice cloning	OmniVoice voice clone path bol odstránený z UI v v0.6.5 W7	Plánovaná náhrada cez ElevenLabs cloud (post v0.8.0)

LIVEKIT INFRASTRUKTÚRA

V repozitári sa nachádzajú legacy LiveKit token-generation endpointy (`app/api/conversations.py`) a `livekit.yaml` konfigurácia pre v1.0 conversation API. Frontend ich nepoužíva. Produkčný realtime stack je SSE + WebSocket + Wilbur Pixel Streaming. LiveKit kód ostáva ako neaktívna backwards-compatible vrstva.

Softvérový produkt — inštalačný balík

EduTutor.AI je dodávaný ako **jedno-klikový Windows inštalátor** — kompletný produkčný balík bez externých závislostí. Používateľ nepotrebuje Python, Node.js, Docker, ani API kľúče. Celý AI stack beží lokálne na bežnom školskom hardvéri.

18.1 Primárny deliverable

EXE FORMÁT BALÍKA Windows NSIS inštalátor	~1.9 GB VEĽKOSŤ INŠTALÁTORA Celý stack bundled	5 BUNDLED KOMPONENTOV Bez externých závislostí
--	---	---

ATRIBÚT	HODNOTA
Názov súboru	EduTutor-Setup-X.X.X.exe (aktuálne v0.7.3, in-flight v0.7.4)
Distribúcia	GitHub Releases — github.com/sorrywecan/edututor-ai
Platformy	Windows 10 (64-bit) · Windows 11
Minimálne požiadavky	8 GB RAM · 10 GB voľného miesta · internet pre Edge TTS (voliteľný)
Odporúčané požiadavky	16 GB RAM · NVIDIA GPU (CUDA) pre Pixel Streaming @60fps avatar render
Typ inštalácie	Per-user (bez admin práv) · dáta do %APPDATA%/EduTutor/ —
Licencia	MIT Open-source

18.2 Obsah inštalátora — 5 bundled komponentov

KOMPONENT	TECHNOLÓGIA	VEĽKOSŤ	ÚČEL
CPython 3.11	Embedded Python runtime	~80 MB	Izolovaný Python — žiadny systémový Python nie je potrebný
FastAPI backend	Python 3.11 + Uvicorn	~100 MB	AI tutor service — ~95 endpointov, 23 routerov
Next.js frontend	React 19.2 standalone	~200 MB	Webové rozhranie — 14 stránok, spúšťa sa na localhost:3000
Ollama (CPU)	LLM runtime bez GPU	~122 MB	Lokálny AI model — gemma3:4b auto-download pri prvom spustení
faster-whisper	CTranslate2 int8	~131 MB	Slovenský STT offline — whisper-base auto-download
Wilbur	WebRTC signalling	~10 MB	Pixel Streaming pre UE5 avatar (voliteľný)
UE5 MetaHuman	Cooked UE5.6 build	~2.3 GB	3D avatar — SlovakEdu.exe, distribuovaný samostatne

Softvérový produkt — inštalácia a produkčná pripravenosť

18.3 Inštalácia — 3 kroky

- 01

Stiahnuť a spustiť inštalátor

Stiahnuť `EduTutor-Setup-X.X.X.exe` z GitHub Releases. Spustiť — Windows Security prompt: "More info → Run anyway". Inštalácia prebehne automaticky (per-user, bez admin).
- 02

Prvé spustenie — automatická konfigurácia

Aplikácia sa spustí so splash screen. FirstRunSetup automaticky detekuje hardvér a stiahne AI model (`gemma3:4b` , ~2.5 GB) alebo umožní zadať cloud API kľúč. Možnosť preskočiť — zero-key offline režim aktivovaný automaticky.
- 03

Spustiť a používať

EduTutor.AI sa otvorí v prehliadači na `localhost:3000` . Demo login: `demo@edututor.sk` / `edututor2026` . Všetky 5 servisov štartujú automaticky — žiadna manuálna konfigurácia.

18.4 Produkčná pripravenosť — checklist

Zero-key offline režim (Ollama + Piper + ChromaDB)	Áno	681+ automatizovaných testov v 64 súboroch, 0 hard failures	Áno
6 k6 záťažových scenárov v repe (smoke · rampup · spike · endurance · STT-heavy · school-day)	Áno	Auto-reštart servisov s exponential backoff	Áno
Graceful degradation — text odpoveď bez TTS/RAG	Áno	Dual-stack health probe (IPv4 + IPv6, Windows fix)	Áno
Hard build gate — Python smoke test pred bundlovaním do .exe	Áno	Fatal error dialog s "Open log folder"	Áno
Per-user inštalácia bez admin práv	Áno	MIT licencia (LICENSE súbor priložený v .exe a v repe)	Áno
Verejný release artefakt .exe + SHA-256 + blockmap (github.com/sorrywecan/edututor-ai)	Áno		

Open-source zverejnenie

Projekt zverejnený pod licenciou **MIT** v súlade s grantovou podmienkou: „*Dosiahnutý výstup bude zdieľaný v open-source databáze.*“

Zdrojový repozitár: <https://github.com/sorrywecan/edututor-ai> — open-source MIT release (plánované W9 2026).

SÚČASŤ	ZAHRNUTÉ	POZNÁMKA
Backend – FastAPI (Python 3.11)	Áno	23 routerov · ~95 endpointov · 30 servisov
Frontend – Next.js 15.5 (React 19.2, TypeScript, Zustand)	Áno	14 stránok · mobile responsive
Desktop – Electron 42 + NSIS inštalátor	Áno	main.mjs · orchestrator.mjs · stage-resources.mjs
Viseme Timeline – SK lipsync (14 vizémov + fonetický engine)	Áno	Coarticulation array · backward-compatible
Emotion Detector – regex SK (9 emócií) + BERT backend	Áno	Slovak-inflected regex · eval report zahrnutý
Skills Platform – web_search · spaced_repetition · memory	Áno	Phase 7 · FSR5-6 · DuckDuckGo + trafilitura
Knowledge Base – Chat/Study/Voice/Ask modes + Podcast	Áno	Full CRUD + streaming · multi-speaker podcast
Testy – 681+ v 64 súboroch + Golden Dataset 354 otázok	Áno	Unit · integrácia · fonetické · API · záťažové
Benchmark skripty – k6 (6 scenárov) + GPU benchmark	Áno	Pipeline · RAG · load testy · school-day sim
Dokumentácia – ADRs · GPU Decision Matrix · lipsync audit	Áno	5 ADR · 250+ parametrov · lipsync codepath audit
API kľúče (.env)	Nie	Vylúčené z bezpečnostných dôvodov
UE5 projekt (MetaHuman assets ~2.3 GB)	Nie	Distribuované samostatne pre artistov
AI modely (Piper, Whisper SK fine-tunes)	Nie — auto-download	Stiahnu sa pri prvom spustení

